Ensemble Methods: Bagging

Ансамблевое обучение (Ensemble Learning)

Ансамблевые методы создают сильную модель, комбинируя прогнозы **нескольких слабых моделей** (также называемых **слабыми обучающимися или базовыми оценками**), построенных с заданным набором данных и заданным алгоритмом обучения.

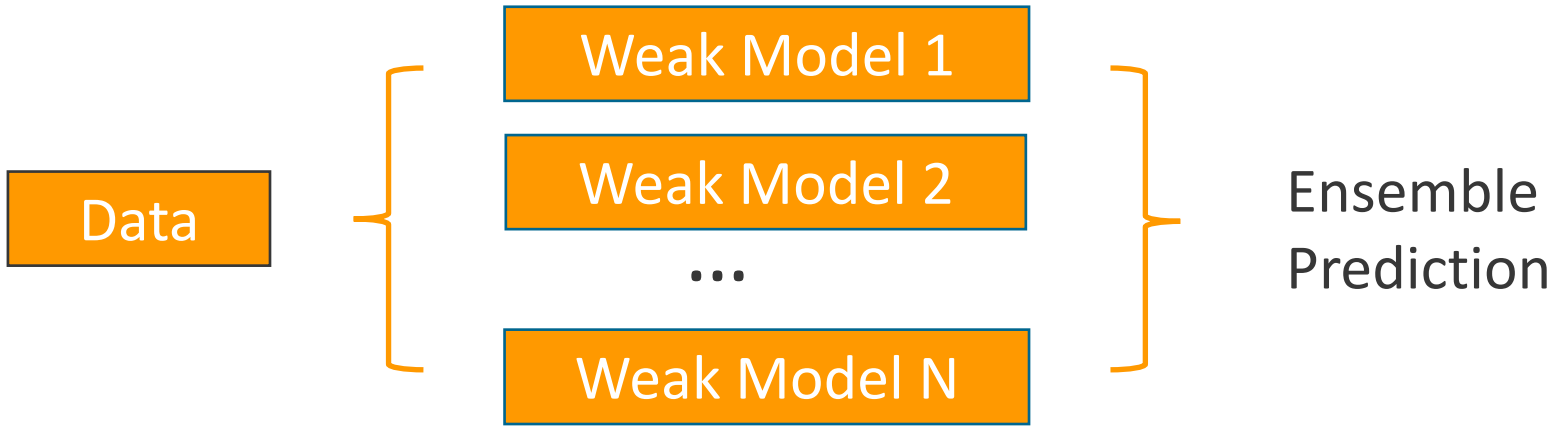

Будем рассматривать модели ансамбля Bagging и Boosting.

Bagging (Bootstrap Aggregating)

Bagging (Bootstrap Aggregating) method:

- Произвольно возьмите N образцов фиксированного размера из обучающего набора (с заменой) - метод **bootstrap**

Example: given data [1, 2, 3, 4, 5, 6, 7, 8, 9], образцы размера 6:

[1, 1, 2, 4, 9, 9]; [2, 4, 5, 5, 7, 7]; [1, 1, 1, 1, 1, 1]; [1, 2, 4, 5, 7,9]

- Создавайте **независимые** оценщики (модели) одного типа для каждого подмножества
- Результат работы ансамбля: голосование по большинству (или взвешенное) или усреднение прогнозов всех оценщиков (для задачи регрессии).

Реализация концепции Bagging Decision Trees: **Random Forest**

Bagging trees: Random Forest

Random Forest: Bagging Decision Trees

- Создайте случайные подмножества (с заменой) из исходного набора данных
- Постройте **дерево решений** для каждого начального подмножества
- Объедините прогнозы из каждого дерева для окончательного прогноза

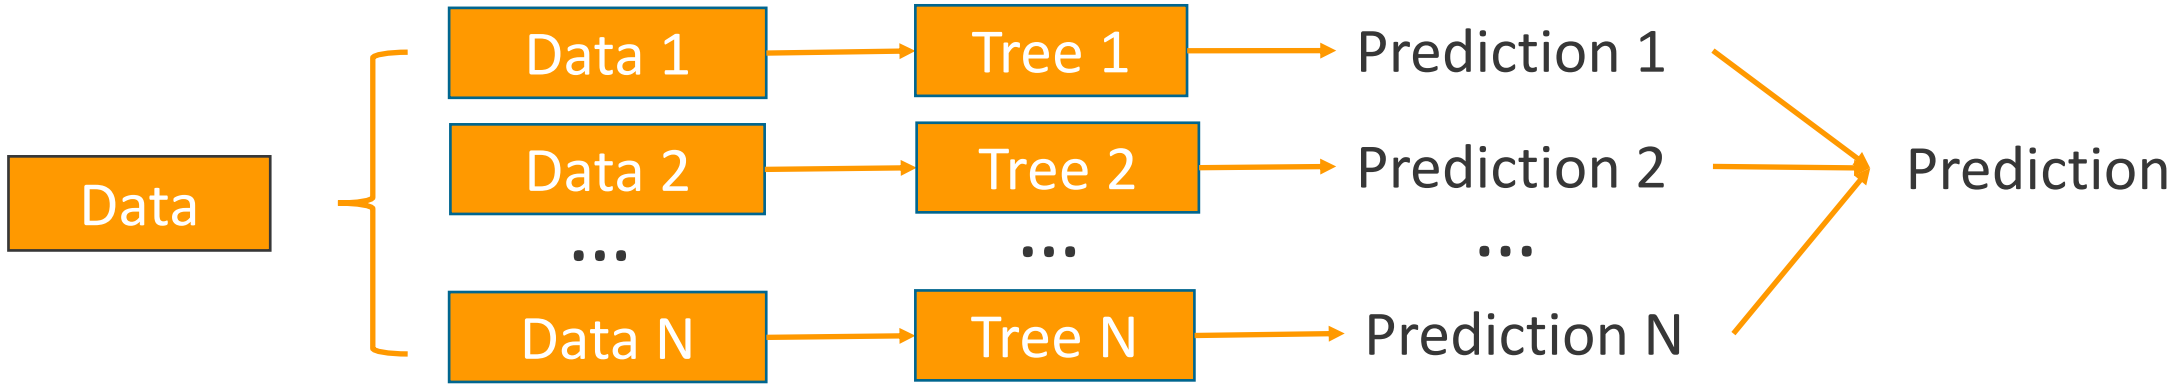

Random Forest in sklearn

RandomForestClassifier: **sklearn** Random Forest classifier (есть версия для Regressor) - .fit(), .predict()

RandomForestClassifier(*n_estimators=100,*
max_samples=None, max_features='auto',
criterion='gini', max_depth=None, min_samples_split=2,
min_samples_leaf=1, class_weight=None)

Полный список параметров гораздо больше.

Bagging in sklearn

BaggingClassifier: sklearn общий интерфейс для bagging который может быть предоставлен любым***base_estimator*** - .fit(), .predict()

BaggingClassifier(*base_estimator=None, n_estimators=10, max_samples=1.0, bootstrap=True*)

Полный список параметров гораздо больше.

Hyperparameter Tuning

Настройка гиперпараметров (Hyperparameter Tuning)

- **Hyperparameters** это **параметры алгоритмов машинного о**бучения, которые влияют на структуру алгоритмов и производительность (качество) моделей.

  Примеры hyperparameters:

  - **K Nearest Neighbors**: n_neighbors, metric
  - **Decision trees:** max_depth, min_samples_leaf, class_weight, criterion
  - **Random Forest**: n_estimators, max_samples
  - **Ensemble Bagging:** base_estimator, n_estimators

- **Hyperparameter tuning** (настройка гиперпараметров) ищет лучшую комбинацию гиперпараметров (комбинацию, которая максимизирует качество модели).

Grid Search in sklearn

GridSearchCV: **sklearn** базовый метод hyperparameter tuning, находит оптимальное сочетание гиперпараметров путем перебора в течение определенных значений параметров -

.fit(), .predict()

GridSearchCV(*estimator*, *param_grid*, *scoring=None)*

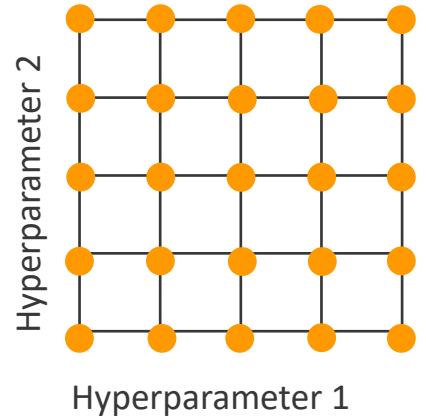

Example: Hyperparameters for a Decision Tree:

param_grid ={max_depth: [5, 10, 50, 100, 250],
min_samples_leaf: [15, 20, 25, 30, 35]}

Total hyperparameters combinations

5 x 5 = 25

[5, 15], [5, 20], [5, 25], [10, 15], …

Randomized Search in sklearn

RandomizedSearchCV: рандомизированный поиск по гиперпараметрам

- Выбирает фиксированное количество (заданное параметром n_iter) случайных комбинаций значений гиперпараметров и пробует только их.
- Возможна выборка из распределений (используется выборка с заменой), если в качестве распределения задан хотя бы один параметр.

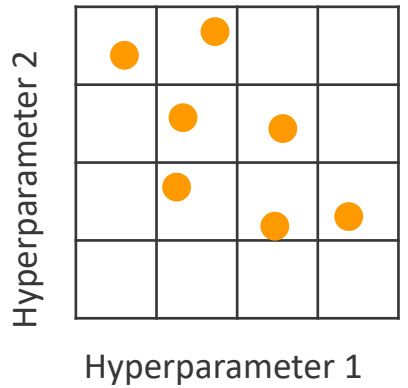

RandomizedSearchCV(*estimator*, *param_distributions*,

n_iter=10, scoring=None)

Example: Hyperparameters for a Decision Tree:

param_grid ={max_depth: [5, 10, 50, 100, 250],
min_samples_leaf: uniform(15,35,5)}

Байесовский поиск (Bayesian Search)

- Метод байесовского поиска (**Bayesian Search**) отслеживает предыдущие оценки гиперпараметров и строит вероятностную модель.
- Он пытается сбалансировать **исследование** (неопределенный набор гиперпараметров) и **реализацию** (гиперпараметры с хорошей вероятностью должны быть оптимальными).
- Предпочитает точки рядом с теми, которые хорошо сработали.

Data Preprocessing with Pipeline (sklean)

Transformers in sklearn

- **SimpleImputer, StandardScaler, MinMaxScaler, LabelEncoder, OrdinalEncoder, OneHotEncoder**, и **CountVectorizer** принадлежат к классу **transformers** sklearn, у всех есть:
  - **.fit()** method: изучает преобразование из **обучающего** набора данных
  - **.transform()** method: применяет преобразование к любому набору данных (**training, validation, test**) для предварительной обработки

К обучающему набору также можно применить **.fit_transform()**

ColumnTransformer in sklearn

ColumnTransformer: применяет преобразователи к столбцам массива или pandas DataFrame – `.fit(), .transform()`

- Позволяет **отдельно преобразовывать** разные столбцы или подмножества входных столбцов (числовые, категориальные, текстовые).
- Функции, генерируемые каждым преобразователем, будут **объединены**, чтобы сформировать **единое пространство функций**.
- Это полезно для смешанных наборов табличных данных, чтобы объединить несколько механизмов извлечения признаков или преобразований в один преобразователь.

ColumnTransformer and Pipeline

```
numerical_processing = Pipeline([
   (‘num_imputer’, SimpleImputer(strategy='mean’)),
   (‘num_scaler’, MinMaxScaler())])

categorical_processing = Pipeline([
   (‘cat_imputer’, Imputer(strategy='constant', fill_value='missing’)),
   (‘cat_encoder’, OneHotEncoder(handle_unknown='ignore’))])

processor = ColumnTransformer(transformers =[
    (‘num_processing’, numerical_processing, ('feature1', 'feature3')),
    (‘cat_processing’, categorical_processing, ('feature0', 'feature2’))])

pipeline = Pipeline([(‘data_processing’, processor),
                     (‘estimator’, KNeighborsClassifier())])

pipeline.fit(X_train, y_train)
predictions = pipeline.predict(X_test)
```